

Cross Entropy Loss in Binary Logistic Regression

رگرسیون لجستیک یک الگوریتم تحت نظارت (supervised) یادگیری ماشین است که برای مسایل طبقه بندی (classification) بکار میرود. برخلاف رگرسیون خطی که مقادیر پیوسته را پیش بینی می کند این الگوریتم احتمال اینکه یک ورودی به یک کلاس مشخص تعلق داشته باشد را پیش بینی می کند و برای طبقه بندی باینری بکار میرود جاییکه خروجی یکی از دو حالت ممکن (بله یا خیر، درست یا نادرست، صفر یا یک و...) باشد. در این مقاله یک معرفی اجمالی از پایه ها و مفاهیم این الگوریتم را خواهیم دید و نکته اصلی، یافتن مشتق تابع هزینه است که من به روشی متفاوت وبا استفاده از خواص تابع سیگموئید آنرا محاسبه کرده ام.

هدف رگرسیون لجستیک باینری، آموزش دادن یک کلاسیفایر (classifier)، (y) است که بتواند در مورد کلاس یک ورودی مشاهده شده، یک تصمیم باینری بگیرد.

یک ورودی مشاهده شده (features)، $x = (x_1, x_2, \dots, x_n)$ را در نظر بگیرید. خروجی کلاسیفایر

y میتواند مقدار 1 را داشته باشد (یعنی ورودی مشاهده شده عضوی از کلاس است) و یا مقدار 0

(یعنی ورودی مشاهده شده عضوی از کلاس نیست). می خواهیم $P(y=1|x)$

یعنی احتمال اینکه ورودی مشاهده شده عضوی از کلاس باشد را بدانیم.

رگرسیون لجستیک می تواند این مساله را با یادگیری از یک مجموعه آموزش یافته، یک بردار

از وزن ها و یک جمله بایاس (Bias Term) or (Intercept) حل نماید.

با فرض اینکه $x = (x_1, x_2, \dots, x_n)$ بردار متغیرهای ورودی و $w = (w_1, w_2, \dots, w_n)$ بردار وزن های

مربوطه (ویا ضرایب) و b عرض از مبدا (ویا جمله بایاس) باشد بکارگیری تابع خطی روی

متغیر ورودی x ، مقدار پیوسته از رگرسیون خطی عبارت خواهد بود از:


$$z = \left(\sum_{i=1}^n w_i x_i \right) + b = w \cdot x + b$$

وزن w_i ضریب متغیر x_i است.

رگرسیون خطی، به منظور تبدیل z به یک احتمال بین صفر و یک، تابع سیگموئید را بکار می گیرد.

تابع سیگموئید (Sigmoid) یا (Logistic Function) عبارتست از:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



این تابع دارای این خاصیت است که مقدار آن همواره بین صفر و یک قرار دارد. همچنین،

$$\sigma(-z) = 1 - \sigma(z)$$

$$\sigma(z) + \sigma(-z) = \frac{1}{1 + e^{-z}} + \frac{1}{1 + e^z} = \frac{1 + e^z + 1 + e^{-z}}{(1 + e^{-z})(1 + e^z)} = \frac{2 + e^z + e^{-z}}{1 + e^z + e^{-z} + e^0} = 1$$

زیرا:

احتمال قرار گرفتن (یا قرار نگرفتن) در یک کلاس را میتوان بصورت زیر در نظر گرفت:

$$P(y=1) = \sigma(z) \quad , \quad P(y=0) = 1 - \sigma(z)$$

وارون تابع سیگموئید، تابع لاجیت (Logit Function) عبارتست از :

$$z = \log it(p) = \sigma^{-1}(p) = \ln \frac{p}{1-p}$$

تابع هزینه L_{CE} (or Cross Entropy Loss):

مقدار واقعی متغیر خروجی $y=0$ or $y=1$ (Correct Output):

مقدارپیش بینی برای متغیر خروجی $\hat{y} = \sigma(w.x + b)$ (classifier)

(توزیع برنولی) $Max: p(y|x) = (\hat{y})^y (1 - \hat{y})^{1-y}$

$$y = 1 \rightarrow \hat{y} = p(1|x), \quad y = 0 \rightarrow p(0|x) = 1 - \hat{y}$$

$$Ln(p(y|x)) = y(Ln(\hat{y})) + (1 - y)(Ln(1 - \hat{y}))$$

قرینه عبارت فوق تابع هزینه نام دارد و آن را با L_{CE} نمایش می دهیم.

$$Min: L_{CE}(\hat{y}, y) = -Ln(p(y|x)) = -[yLn(\hat{y}) + (1 - y)(Ln(1 - \hat{y}))]$$

$$= -[yLn(\sigma(w.x + b)) + (1 - y)(Ln(1 - \sigma(w.x + b)))]$$

$$= -[yLn(\sigma(w.x + b)) + (1 - y)(Ln(\sigma[-(w.x + b))])]$$

مشتق جزئی تابع هزینه نسبت به w_j :

در اینجا می خواهیم ثابت کنیم که مشتق جزئی تابع هزینه (یعنی L_{CE}) نسبت به w_j عبارتست از:

$$x_j [\sigma(w.x + b) - y]$$

Proof:

$$\frac{\partial L_{CE}}{\partial w_j} = -y \left[\frac{\sigma'(w.x + b)}{\sigma(w.x + b)} \right] - (1 - y) \left(\frac{\sigma'[-(w.x + b)]}{\sigma[-(w.x + b)]} \right) =$$

$$-y \left[\frac{\sigma'(w.x + b)}{\sigma(w.x + b)} - \left(\frac{\sigma'[-(w.x + b)]}{\sigma[-(w.x + b)]} \right) \right] - \left(\frac{\sigma'[-(w.x + b)]}{\sigma[-(w.x + b)]} \right) =$$

$$y \left[\frac{-x_j e^{w.x + b}}{1 + e^{w.x + b}} - \frac{x_j e^{-(w.x + b)}}{1 + e^{-(w.x + b)}} \right] - \left(\frac{-x_j e^{w.x + b}}{1 + e^{w.x + b}} \right) = y(-x_j) + x_j \left(\frac{1}{e^{-(w.x + b)} + 1} \right) =$$

$$-yx_j + x_j \sigma = x_j (\sigma - y)$$

کد پایتون مربوط به یک مثال ساده از اجرای رگرسیون لجستیک و محاسبه هزینه لجستیک را میتوانید در لینک زیر مشاهده نمایید.

<https://github.com/sharifzadeh173/my-page>